Checkpoint 3 - Grupo 33

Introducción

En todos los modelos decidimos no reemplazar los NANs de *Company* y *Agent* por su media, que fue lo que hicimos anteriormente. En vez, los reemplazamos por un -1 para indicar que eran su propia categoría. Con esta misma idea, para ciertos modelos rápidos probamos agregar estas dos columnas en el One Hot Encoding para poder tratarlas verdaderamente como variables cualitativas, aunque nos terminamos arrepintiendo porque empeoraron los porcentajes.

En ciertos modelos decidimos reescribir la fecha en una cierta forma numérica para que el modelo la pueda interpretar (utlizando la funcion *toordinal*).

Para SVM que fue un modelo que tardó mucho tiempo en construirse intentamos hacer un poco de Feature Engineering y PCA (con pipeline) para dimensionar. Cuando realizamos el F.E. nos dimos cuenta que todas las columnas de *reserved_room_type* estaban muy fuerte correlacionadas a su correspondiente *assigned_room_type*. Lo mismo pasaba con *market_segment_Undefined* y *distribution_channel_Undefined,* las cuales ni siquiera aparecen en el dataset de testeo. Pero, cuando realizamos PCA, terminó dando un valor peor a si si directamente utilizabamos un menor porcentaje para training, por lo cual no lo terminamos utilizando.

Construcción del modelo (Hiperparametros)

KNN: {'weights': 'distance', 'n_neighbors': 24, 'metric': 'manhattan', 'algorithm': 'kd_tree'}
SVN: Corrimos tres formas diferentes; sin parámetros, con un kernel lineal y otro con RandomSearchCV para encontrar sus mejores hiperparametros para una kernel poly. Estos hiperparametros son: {'gamma': 0.00046415888336127773, 'degree': 2, 'coef0': -0.30000000000000016, 'C': 61}

XGBOOST: {'subsample': 0.7, 'objective': 'binary:logistic', 'n_estimators': 638, 'max_depth': 25, 'learning_rate': 0.1, 'lambda': 0, 'gamma': 1, 'colsample_bytree': 1.0, 'alpha': 0.1}

Random Forest: {'n_estimators': 52, 'min_samples_split': 5, 'min_samples_leaf': 1, 'max_depth': 47, 'criterion': 'entropy'}
Voting: Utilizamos los modelos Random Forest, XGBoost y Árbol de Decisión.
Stacking: Utilizamos los modelos Random Forest, XGBoost y Árbol de Decisión como Modelos Base y otro XGBoost como Meta Modelo.

Cuadro de Resultados

Modelo	F1-Test	Presicion Test	Recall Test	Accuracy	Kaggle
KNN	0.7666666666666666	0.7514613778705637	0.7825	0.7640788198557122	0.7676
SVM	0.8071126531497343	0.8130483853351295	0.8012629615012027	0.8084419080435017	0.80854
Random Forest	0.8724002868648978	0.8857398902206789	0.8594565217391305	0.875471088618499	0.87285
XGBoost	0.8844475569681624	0.883543213862878	0.8853537532355479	0.8845159900936793	0.87989
Voting	0.8793937439535634	0.8764731090636383	0.8823339085418465	0.8791859588672337	0.87437
Stacking	0.8803308626060802	0.8768457093943933	0.8838438308886971	0.8800473780553462	0.88065

Nuestro mejor modelo fue Stacking, lo cual tiene sentido lógico ya que este utiliza tres modelos no híbridos como modelos base y luego vuelve a usar XGBoost para actuar como modelo de “votación”. Este modelo tiene la gran ventaja de que se va entrenando a partir de lo que aprenden modelos anteriores, y a diferencia de Voting este hace otro tipo de lógica para poder decidir con qué resultado quedarse, en vez de quedarse con el promedio.

KNN terminó siendo nuestro peor modelo, lo cual era de esperarse. Este modelo se

basa en predecir resultados a partir de observaciones “cercanas”. Este modelo es muy sensible a outliers y a conjuntos de datos no balanceados. Por lo cual, aunque le hicimos un tratamiento a los outliers, igualmente estos tuvieron su peso en el resultado final, lo cual se puede ver en su puntaje bajo de Accuracy.

Matriz de Confusion

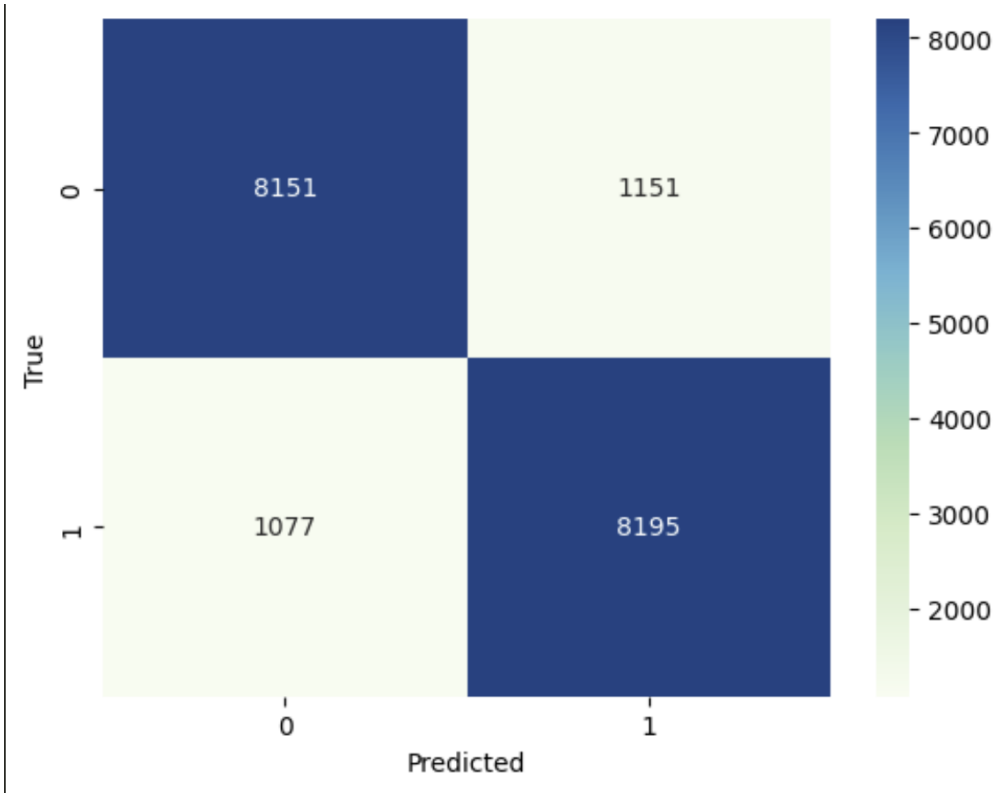

Se puede apreciar cómo obtuvimos pocos falsos positivos y falsos negativos

Tareas Realizadas

Integrante	Tarea
Lucas Raimondi	XGBoost, Stacking, Voting, RF, KNN
Manuel Davila	XGBoost, SVM, KNN, RF, Informe
Dolores Levi	XGBoost, SVM, KNN, RF, Informe